دليل بناء لائدكس انطلاقا من جيس

من فكرة لغوية إلى نموذج أولي يقاس ويختبر

كيف أفكر كمهندس تعلم آلي

لا نبدأ بالادعاء أننا سنبني نموذجا أذكى من الجميع. نبدأ بفرضية واضحة: هل تجعل معرفة الجذر والوزن والتشكيل النموذج أدق من جيس وحده في مهام عربية محددة؟

النجاح هو تحسن موثق في الاختبارات، وليس وصفا فلسفيا للنموذج.

قرار البداية

النموذج الأساسي

Jais Base 2.7B

حجم مناسب للتجارب الجادة. نحتفظ بتقطيعه في البداية، ثم نضيف معرفة عربية جانبية بدلا من تغيير كل شيء دفعة واحدة.

ثلاثة مخرجات يجب أن نصل إليها

واحد

معيار أساس

تشغيل جيس كما هو، وتسجيل نتائجه على مهام مختارة.

اثنان

طبقة عربية

استخراج الجذر والوزن والتشكيل ثم دمجها داخل النموذج.

ثلاثة

قرار مدعوم

مقارنة عادلة تقرر هل نوسع العمل أم نغير الفرضية.

قاعدة التدريب

كل تجربة تملك سؤالا واحدا، بيانات ثابتة، معيار نجاح، وسجل نتائج قابل للتكرار.

النظام الذي سنبنيه

نضيف المعرفة العربية كمسار منظم بجانب جيس، لا كبديل غامض عنه.

مسار البيانات والفهم



في أول نسخة: الخصائص الصوتية تصف الحرف والتشكيل، ولا تدعي قياس ظواهر فيزيائية من نص فقط.

المكونات ومسؤولية كل مكون

تطبيع النص

يحافظ على الحروف والتشكيل، ويوحد الاختلافات الإملائية دون محو المعلومة.

محلل صرفي

يعطي احتمالات للجذر والوزن والنوع النحوي، ولا يتظاهر بأن تحليله يقيني دائما.

مشفّر الخصائص

يحوّل الجذر والوزن والحركات والتفخيم والترقيق إلى متجهات عددية.

طبقة الدمج

تتعلم متى تستخدم الخصائص العربية ومتى تعتمد على سياق جيس النصي.

مقوّم النتائج

يقارن النموذج الأساسي والنموذج المعدل على نفس البيانات ونفس المقاييس.

لا نبدل التوكنيزر في البداية. نختبر الإضافة الجانبية أولا، ثم نوسع المفردات فقط إذا أثبتت النتائج الحاجة إليها.

العمل على مراحل قصيرة

لا تنتقل إلى المرحلة التالية قبل تسليم مخرج واضح ومراجعته مع الفريق.

الأسبوع الأول
مرحلة

تحديد الفرضية والقياس

اختيار مهمة أولى مثل التشكيل أو التحليل الصرفي. تثبيت بيانات الاختبار والمقياس وخط الأساس.

المخرج: وثيقة تجربة ومعيار أساس

من الثاني إلى الرابع
مرحلة

تشغيل النموذج الأساسي

تشغيل جيس بدون إضافات. تنظيف البيانات وبناء سجل تجارب، ثم حفظ النتائج لتكون مرجعا لا يتغير.

المخرج: نتائج جيس الأساسية

من الخامس إلى السابع
مرحلة

طبقة الصرف والتشكيل

إدخال الجذر والوزن والنوع الصرفي والتشكيل كخصائص مرافقة. ابدأ بمهمة واحدة ولا تضرف الصوت بعد.

المخرج: نسخة صرفية قابلة للتدريب

من الثامن إلى الحادي عشر
مرحلة

الدمج والتدريب الجزئي

استعمل طبقة دمج صغيرة وتدريبا جزئيا بدلا من إعادة تدريب النموذج كله. قارن النتيجة مع معيار الأساس.

المخرج: نموذج لاندكس الأول

من الثاني عشر إلى الرابع عشر
مرحلة

الخصائص الصوتية

أضف خصائص قابلة للتعريف مثل موضع النطق والتفخيم والجهر والحركات. ألغ أي خاصية لا تحسن القياس.

المخرج: تقرير أثر الخصائص

من الخامس عشر إلى السادس عشر
مرحلة

تقييم وقرار

اختبر على بيانات لم يرها النموذج. راجع الأخطاء مع مختص لغوي، ثم قرر التوسعة أو التصحيح أو التوقف.

المخرج: عرض تجريبي وقرار المرحلة التالية

كيف أعرف أنني أتقدم

المدرب لا يقبل عبارة النموذج يبدو أفضل. نحتاج أدلة، وأخطاء مفهومة، وقرارا مبنيا على القياس.

مؤشرات النجاح الأولى

الفهم

تحسن في المهمة المستهدفة دون تراجع واضح في جودة التوليد.

الصرف

دقة الجذر والوزن والنوع النحوي عند وجود مرجع.

التشكيل

انخفاض أخطاء الحركات على مجموعة اختبار ثابتة.

قواعد عمل المتدرب

- لا تغير البيانات والموديل والمقياس في التجربة نفسها، وإلا فلن تعرف سبب النتيجة.
- اكتب سبب كل تجربة قبل تشغيلها، وسجل النتيجة حتى عندما تفشل.
- لا تعامل الجذر كمعنى كامل؛ السياق هو الذي يحسم المقصود.
- اعتبر مخرجات المحلل الصرفي احتمالات، خاصة عند النص غير المشكل واللهجات.
- لا تستخدم بيانات بلا رخصة واضحة أو تحتوي معلومات شخصية حساسة.

متى ننتقل إلى المرحلة التالية

- نتائج النموذج المعدل تتفوق على جيس الأساسي في المهمة المتفق عليها وبنفس مجموعة الاختبار.
- التحسن يتكرر في أكثر من تشغيل، وليس نتيجة صدفة أو ضبط مخصص لمجموعة الاختبار.
- يمكن للفريق شرح الأخطاء المتبقية وفهم أثر كل مكون جديد.

أول مهمة لك

- جهز بيئة تشغيل جيس الأساسية.
- اختر مجموعة اختبار عربية صغيرة مرخصة.
- شغل معيار الأساس وسجل النتيجة.
- اعرض علي تقريرا من صفحة واحدة: ما الذي قسته، وما الذي تعلمته، وما تجربة الأسبوع القادم؟